

具冒充者與欺騙攻擊偵測之語者辨識

日期：04/28

講者：許正欣老師

一、語者辨識 (Speaker Recognition) 基礎概念

語者辨識是透過說話者的語音特徵來辨別其身分。

- **辨識類型：**
 - **語者驗證 (Speaker Verification)：**確認說話者是否為宣稱的特定對象（一對一比對）。
 - **語者識別 (Speaker Identification)：**從一組已知的說話者中，識別出當前的說話者是誰（一對多比對）。
- **語句限制：**
 - **本文相關 (Text-dependent)：**限制辨識的語句內容，辨識效果通常較好，但模型較不易訓練。
 - **本文無關 (Text-independent)：**不論說話內容，直接進行身分辨認。

二、系統面臨的威脅與攻擊類型

語者辨識系統主要面臨兩類威脅：**冒充者 (Imposter)** 與 **欺騙攻擊 (Spoofing attacks)**。

1. **冒充者 (Imposter)：**非註冊語者試圖冒充合法用戶。
2. **欺騙攻擊 (Spoofing attacks)：**以人為假造的聲音進行攻擊。
 - **人聲模仿 (Impersonation)。**
 - **錄音回放 (Replay)：**屬於物理性訪問 (Physical Access)，透過麥克風進行攻擊。
 - **語音合成 (Speech synthesis) 與 語音轉換 (Voice conversion)：**屬於邏輯性訪問 (Logical Access)，繞過麥克風直接攻擊系統。

三、系統架構圖

研究提出的系統採兩階段偵測架構，以確保安全性：

- **第一階段：偵測攻擊階段**
 - 擷取 **CQCC** 語音特徵。
 - 使用**二元分類偵測攻擊模型**判斷是否為生成語音或錄音。
 - 若判定為「拒絕」，則不進入下一階段。
- **第二階段：語者辨識階段**
 - 擷取 **MFCC** 與 **i-vector** 特徵。
 - 採用**整體學習 (Ensemble Learning)** 策略，整合單模型 DNN、多模型 DNN、Linear SVM、Kernel SVM 及 Random Forest 等多個分類器。
 - 最終輸出辨識結果（接受或拒絕）。

四、 關鍵語音特徵擷取技術

1. CQCC (Constant Q Cepstral Coefficients)：

- 結合了**常數 Q 轉換 (CQT)** 與倒頻譜處理。
- **CQT 特色**：頻率軸為對數標度 (Log scale)，且視窗長度隨頻率改變。
- 對聲音細微變化更敏感，符合人耳聽覺系統，特別適合偵測欺騙攻擊，特徵維度為 60 維。

2. i-vector：

- 基於**聯合因子分析 (JFA)** 方法，通常搭配 MFCC 擷取。
- 需利用非註冊語者語料建立**通用背景模型 (UBM)**。
- 能將不固定長度的特徵降維成 **400 維的固定長度向量**，降低特徵複雜度。其數學表示式為 $\mathbf{v} = (\mathbf{A}^T \mathbf{A} + \lambda \mathbf{I})^{-1} \mathbf{A}^T \mathbf{y}$ ，其中 $\mathbf{A}$ 為低秩的 Total variability 矩陣。

五、 決策機制與優化策略

- **門檻值 (Threshold) 決策：**

- **偵測攻擊模型**：數值小於門檻值判定為生成語音，反之為真實語音。
- **語者辨識模型**：數值小於門檻值判定為冒充者，反之為目標語者。
- **分數正規化 (Score Normalization)**：目的是拉開目標語者與冒充者的分數分佈，以便尋找強健的門檻值。實驗顯示在不同語料庫下，正規化能顯著提升阻擋率。
- **全數決整體學習 (Unanimity voting ensemble learning)**：
 - 必須所有分類器都達成相同決策，才允許進入系統。
 - 能有效抵擋冒充者，但也會提升錯誤拒絕目標語者的機率。
- **條件式重試機制 (Conditional Retry)**：
 - 為了減緩全數決帶來的錯誤拒絕，當系統判定為拒絕時，在滿足條件下允許 1~2 次重新辨識機會。
 - 當判定有冒充者時，系統會關閉一段時間並發出警告通知。

六、實驗評估結果

- **評估指標**：使用**混淆矩陣 (Confusion Matrix)**，包含正確率 (ACC)、真陽率 (TPR) 及偽陽率 (FPR)。
- **特徵比較**：在欺騙攻擊偵測中，**CQCC (91.6%)** 的正確率顯著優於 MFCC (71.0%) 與 i-vector (75.3%)。
- **分類器比較**：使用 Single-model DNN (91.6%) 的效果優於 RBF-SVM (90.0%) 與 Linear-SVM (83.3%)。
- **靜音移除實驗**：保留語音中的靜音（音素間的短暫停頓）有助於提升偵測正確率 (91.6%)，移除靜音後正確率反而下降至 86.8%。
- **系統整合效能**：
 - 整合後的語者辨識系統，在阻擋欺騙攻擊的表現可達 **97.5%**。
 - 對於冒充者的阻擋率，在不同測試語料庫（如語料庫 A, B, C）中均表現優異，最高可達 100%。

七、 未來探討方向

- **欺騙攻擊偵測**：考慮將模型設計為**遞迴神經網路 (RNN)**，以解決輸入音訊長度不一的問題。
- **語者辨識模型**：針對整體學習進行超參數最佳化，以進一步降低複雜度並改善系統效能。