

具冒充者與欺騙攻擊偵測之語者辨識

日期：04/28

講者：許正欣老師

關鍵字：語者辨識、欺騙攻擊偵測、語音特徵擷取、安全驗證

一、語者辨識 (Speaker Recognition) 基礎概念

語者辨識是一種利用「人的聲音特徵」來辨認身分的技術。

系統會分析每個人說話時獨有的聲學特徵，例如：

- 聲帶震動方式
- 共振腔特性
- 發音習慣
- 音高與音色
- 語速與停頓模式

由於每個人的生理構造與說話習慣不同，因此聲音具有一定程度的「個體唯一性」，可作為生物特徵辨識 (Biometric Recognition) 的一種。

- 語者辨識常應用於：
- 手機語音解鎖
- 智慧助理身分確認
- 電話客服驗證
- 金融語音認證
- 法醫聲紋分析
- 智慧居家設備
- 辨識類型：
 - **語者驗證 (Speaker Verification)**：確認說話者是否為宣稱的特定對象（一對一比對）。
 - **語者識別 (Speaker Identification)**：從一組已知的說話者中，識別

出當前的說話者是誰（一對多比對）。

- **語句限制：**

- **本文相關 (Text-dependent)：**限制辨識的語句內容，辨識效果通常較好，但模型較不易訓練。
- **本文無關 (Text-independent)：**不論說話內容，直接進行身分辨認。

二、系統面臨的威脅與攻擊類型

雖然語者辨識系統能利用聲音進行身分驗證，但實際應用中仍面臨許多安全風險。攻擊者可能透過模仿、錄音或 AI 生成聲音等方式，試圖欺騙系統以非法取得存取權限。

語者辨識系統主要面臨兩類威脅：**冒充者 (Imposter)** 與 **欺騙攻擊 (Spoofing attacks)**。

1. **冒充者 (Imposter)：**未經授權的使用者，試圖假冒合法用戶進入系統。
2. **欺騙攻擊 (Spoofing attacks)：**利用人工製造或修改後的聲音，欺騙語者辨識系統。
 - **人聲模仿 (Impersonation)。**
 - **錄音回放 (Replay)：**屬於物理性訪問 (Physical Access)，透過麥克風進行攻擊。
 - **語音合成 (Speech synthesis) 與 語音轉換 (Voice conversion)：**屬於邏輯性訪問 (Logical Access)，繞過麥克風直接攻擊系統。

三、系統架構圖

研究提出的系統採兩階段偵測架構，以確保安全性：

- **第一階段：偵測攻擊階段**
 - 擷取 CQCC 語音特徵。
 - 使用二元分類偵測攻擊模型判斷是否為生成語音或錄音。
 - 若判定為「拒絕」，則不進入下一階段。
- **第二階段：語者辨識階段**

- 擷取 **MFCC** 與 **i-vector** 特徵。
- 採用 **整體學習 (Ensemble Learning)** 策略，整合單模型 DNN、多模型 DNN、Linear SVM、Kernel SVM 及 Random Forest 等多個分類器。
- 最終輸出辨識結果（接受或拒絕）。

四、 關鍵語音特徵擷取技術

1. CQCC (Constant Q Cepstral Coefficients)：

- 結合了**常數 Q 轉換 (CQT)** 與倒頻譜處理。
- **CQT 特色**：頻率軸為對數標度 (Log scale)，且視窗長度隨頻率改變。
- 對聲音細微變化更敏感，符合人耳聽覺系統，特別適合偵測欺騙攻擊，特徵維度為 60 維。

2. i-vector：

- 基於**聯合因子分析 (JFA)** 方法，通常搭配 MFCC 擷取。
- 需利用非註冊語者語料建立**通用背景模型 (UBM)**。
- 能將不固定長度的特徵降維成 **400 維的固定長度向量**，降低特徵複雜度。其數學表示式為 $\mathbf{v} = \mathbf{W} \mathbf{z}$ ，其中 $\mathbf{z}$ 為低秩的 Total variability 矩陣。

五、 決策機制與優化策略

• 門檻值 (Threshold) 決策：

- **偵測攻擊模型**：數值小於門檻值判定為生成語音，反之為真實語音。
- **語者辨識模型**：數值小於門檻值判定為冒充者，反之為目標語者。

- **分數正規化 (Score Normalization)**：目的是拉開目標語者與冒充者的分數分佈，以便尋找強健的門檻值。實驗顯示在不同語料庫下，正規化能顯著提升阻擋率。

• 全數決整體學習 (Unanimity voting ensemble learning)：

- 必須所有分類器都達成相同決策，才允許進入系統。

- 能有效抵擋冒充者，但也會提升錯誤拒絕目標語者的機率。
- **條件式重試機制 (Conditional Retry)：**
 - 為了減緩全數決帶來的錯誤拒絕，當系統判定為拒絕時，在滿足條件下允許 1~2 次重新辨識機會。
 - 當判定有冒充者時，系統會關閉一段時間並發出警告通知。

六、實驗評估結果

- **評估指標：**使用混淆矩陣 (Confusion Matrix)，包含正確率 (ACC)、真陽率 (TPR) 及偽陽率 (FPR)。
- **特徵比較：**在欺騙攻擊偵測中，CQCC (91.6%) 的正確率顯著優於 MFCC (71.0%) 與 i-vector (75.3%)。
- **分類器比較：**使用 Single-model DNN (91.6%) 的效果優於 RBF-SVM (90.0%) 與 Linear-SVM (83.3%)。
- **靜音移除實驗：**保留語音中的靜音（音素間的短暫停頓）有助於提升偵測正確率 (91.6%)，移除靜音後正確率反而下降至 86.8%。
- **系統整合效能：**
 - 整合後的語者辨識系統，在阻擋欺騙攻擊的表現可達 **97.5%**。
 - 對於冒充者的阻擋率，在不同測試語料庫（如語料庫 A, B, C）中均表現優異，最高可達 100%。

七、未來探討方向

- **欺騙攻擊偵測：**考慮將模型設計為遞迴神經網路 (RNN)，以解決輸入音訊長度不一的問題。
- **語者辨識模型：**針對整體學習進行超參數最佳化，以進一步降低複雜度並改善系統效能。

八、參考文獻

[1] D. Snyder, D. Garcia-Romero, G. Sell, D. Povey and S. Khudanpur, "X-Vectors: Robust DNN Embeddings for Speaker Recognition," *2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, Calgary, AB,

Canada, 2018, pp. 5329-5333

[2] Kinnunen, Tomi & Evans, Nicholas & Yamagishi, Junichi & Lee, Kong Aik & Sahidullah, Md & Todisco, Massimiliano & Delgado, Héctor. (2018). ASVspoof 2017: Automatic Speaker Verification Spoofing and Countermeasures Challenge Evaluation Plan

[3] Zhizheng Wu, Nicholas Evans, Tomi Kinnunen, Junichi Yamagishi, Federico Alegre, Haizhou Li, Spoofing and countermeasures for speaker verification: A survey, Speech Communication, Volume 66, 2015, Pages 130-153

九、心得

這次整理語者辨識與抗欺騙語音系統的相關內容後，我更清楚理解這類系統在實際應用中的完整架構與限制。過去我對語者辨識的認知主要停留在「用聲音辨認身分」的概念，但實際上系統必須同時處理語者驗證與語者識別兩種不同任務，並且還要面對文本相關與文本無關等條件差異，使得問題的複雜度遠高於一般分類問題。